Chloé Blanc

Projet citoyen : Les biais de l'IA

CPA2 - INFO 25/26

Table des matières

1. Introduction : Le mythe de l'objectivité algorithmique 3
2. Comprendre les biais en intelligence artificielle 4
3. L'IA au miroir de nos préjugés : analyse de cas 5
A. Discrimination à l'embauche 5
B. Publicité ciblée et stéréotypes 5
C. Justice prédictive 5
D. Santé et accès aux soins 6
E. Vision par ordinateur et IA générative 6
4. De la prise de conscience à l'engagement citoyen 7
A. Sensibilisation dans l'espace public 7
B. Témoignages et perception citoyenne 8
C. Interpellation des étudiants ingénieurs 9
D. Vulgarisation numérique 9
7. Conclusion : responsabilité et perspectives 10
8. Ressources et annexes 11
Ressources 11
Annexes 11

1. Introduction : Le mythe de l'objectivité algorithmique

Nous pensons tous que l'intelligence artificielle représente comme une forme de rationalité pure. Or, face aux biais humains, aux discriminations et aux jugements subjectifs, elle apparaît souvent comme une solution idéale : pour faire un tirage au sort, pour choisir une idée plutôt qu'une autres ou même pour répondre à une situation complexe.

L'IA est une machine supposée objective, guidée uniquement par les mathématiques et les données.

Pourtant, cette vision est trompeuse.

L'idée de choisir un sujet comme celui-ci pour notre projet est né d'une situation simple. Lors d'un exercice technique, nous avons demandé à une intelligence artificielle de générer une liste de prénoms pour une base de données. Le résultat obtenu nous a frapper : une majorité écrasante de prénoms occidentaux et masculins, avec très peu de diversité.

Ce constat, qui peut sembler normal, a agi comme un déclencheur. Si une IA ne parvient pas à représenter la diversité du monde sur une tâche aussi simple, comment peut-elle être fiable dans des domaines critiques comme :

- le recrutement
- la justice
- la santé
- ou encore la sécurité

Cette interrogation a constitué le point de départ de notre réflexion.

Dans ce rapport je vais vous aborder 3 points :

- nous allons comprendre l'origine des biais algorithmiques
- ensuite nous analyserons leurs impacts concrets
- et enfin nous présenterons les actions citoyennes que nous avons menées pour combattre, à notre échelle, ces inégalités.

2. Comprendre les biais en intelligence artificielle

Contrairement à une idée répandue, une IA n'est pas vraiment 'intelligente'. Elle apprend à partir de données existantes, qu'elle va pouvoir récupérer sur internet et tout autre réseaux..

Ainsi, un principe fondamental s'impose :

une IA reproduit ce qu'on lui montre

Si les données qui l'entraînent contiennent :

- des déséquilibres
- des stéréotypes
- ou des discriminations

alors l'algorithme les intégrera et les amplifiera, car pour lui ce sera la 'norme'.

Ce phénomène est souvent résumé par l'expression :

"Garbage in, garbage out"

Comme le rappelle Luc Julia, un expert en IA, l'intelligence artificielle n'est pas une entité autonome capable de jugement moral. Elle est un outil statistique qui reflète les données humaines.

Et cette réalité implique une responsabilité majeure pour les concepteurs.

3. L'IA au miroir de nos préjugés : analyse de cas

A. Discrimination à l'embauche

En 2018, Amazon a développé un outil de recrutement basé sur l'IA. Mais pourtant, celui-ci a rapidement été abandonné.

Pourquoi ?
Parce qu'il discriminait systématiquement les femmes.

L'algorithme avait été entraîné sur des CV historiques majoritairement masculins. Il a donc appris que les profils masculins étaient « préférables ».

Conséquence directe :

- pénalisation automatique de certains mots liés au genre féminin
- reproduction des inégalités existantes

B. Publicité ciblée et stéréotypes

Les algorithmes publicitaires ne sont pas neutres.

Une étude a montré que :

- les offres de caissiers étaient majoritairement montrées à des femmes
- les offres de chauffeurs étaient davantage montrées à des personnes racisées

Ces biais ne provenaient pas des recruteurs, mais des systèmes de diffusion eux-mêmes.

C. Justice prédictive

Le logiciel COMPAS, utilisé aux États-Unis pour évaluer le risque de récidive, a révélé des biais raciaux importants.

Faits marquants :
les personnes noires étaient deux fois plus susceptibles d'être classées à tort comme « à haut risque ».

Cela pose une question fondamentale :

Peut-on confier des décisions judiciaires à des systèmes biaisés ?

D. Santé et accès aux soins

Dans le domaine médical, certains algorithmes ont utilisé les dépenses de santé comme indicateur de gravité.

Problème :
les populations défavorisées ayant historiquement moins accès aux soins, elles apparaissaient comme « moins malades ».

Conséquence :

- *sous-évaluation des besoins*
- *accès réduit aux soins intensifs*

E. Vision par ordinateur et IA générative

Les travaux sur la reconnaissance faciale ont mis en évidence des écarts majeurs :

- très faible taux d'erreur pour les hommes blancs
- taux d'erreur élevé pour les femmes à la peau foncée

Cela nous montre que les IA génératives renforcent également certains stéréotypes :

- *faible représentation des femmes dans les métiers techniques*
- *surreprésentation d'hommes dans les postes de pouvoir*

4. De la prise de conscience à l'engagement citoyen

Notre projet s'est articulé autour de trois axes principaux, nous voulions agir sur différentes plateformes et permettre à tous de pouvoir s'informer sur ce sujet encore méconnu.

Voici nos différents terrains d'action :

- Une sensibilisation sur le terrain
- Des échanges avec les citoyens
- Une sensibilisation au sein même de l'école

A. Sensibilisation dans l'espace public

Nous avons conçu et distribué des prospectus pédagogiques.

<u>Objectif :</u>

- expliquer simplement les biais de l'IA
- provoquer une prise de conscience

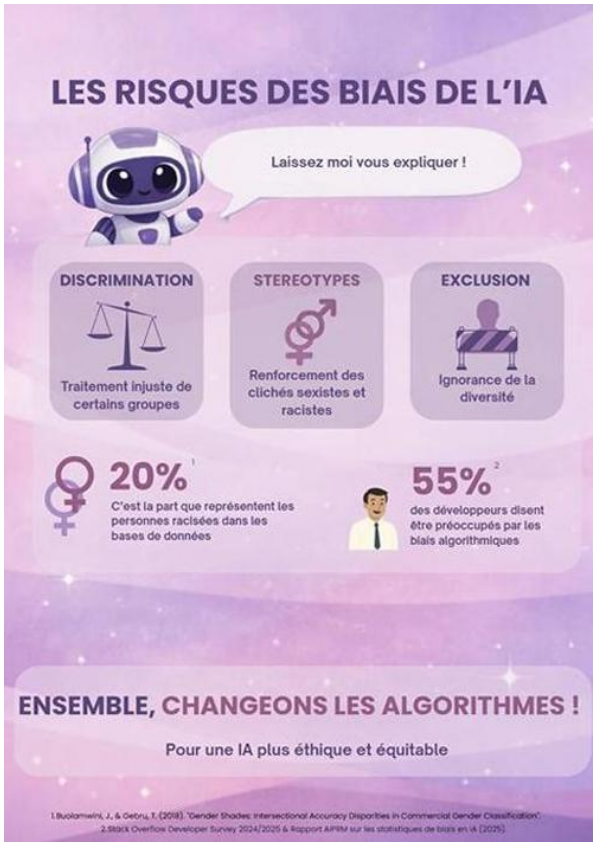

B. Témoignages et perception citoyenne

Le 23/03/2026, nous avons décidés de parler avec des passants dans les rues de Strasbourg en les abordant avec une simple question :

Pensez-vous que l'IA puisse être raciste ou sexiste ?

Ces échanges ont permis de recueillir des témoignages variés, révélateurs de la perception actuelle de l'intelligence artificielle.

Dans un premier temps, la majorité des personnes interrogées exprimaient une confiance spontanée envers ces technologies, souvent perçues comme neutres et objectives. Cependant, la présentation d'exemples concrets de biais a rapidement suscité des réactions plus nuancées, mêlant surprise, inquiétude et réflexion critique.

Voici certaines des réactions que nous avons trouvées pertinentes de retenir :

> « *Je pensais que les plateformes de recrutement étaient objectives. Maintenant, je me demande si mon profil est vraiment évalué équitablement. C'est inquiétant de se dire qu'un algorithme peut nous pénaliser sans qu'on le sache*. »

De la même manière, un salarié a souligné l'impact des algorithmes sur les choix professionnels :

> « *Je n'avais jamais remarqué que les offres qu'on me propose sont toujours les mêmes. On a l'impression d'être enfermé dans une case en fait*. »

Dans le domaine éducatif, une enseignante a insisté sur l'importance de développer l'esprit critique des élèves :

> « *L'IA est souvent présentée comme objective, mais elle reflète aussi les biais de la société. Il est essentiel d'apprendre aux jeunes à questionner ces outils*. »

Au sein même du milieu scientifique, certains des nos camarades ont également exprimé une évolution de leurs opinions :

> « *On se concentre beaucoup sur la performance technique, mais on oublie parfois l'impact social. Ce projet m'a fait réaliser notre responsabilité en tant que futurs ingénieurs*. »

Nous avons aussi pu remarquer que les préoccupations sont particulièrement marquées dans les domaines sensibles.

Une professionnelle de santé a ainsi déclaré :

> « *Si un algorithme sous-estime les besoins de certains patients, cela peut avoir des conséquences graves. On ne peut pas ignorer ces biais*. »

Pour finir, plusieurs participants ont eu une réflexion plus globale sur le rôle de la société :

> « *Ce qui m'a marqué, c'est que l'IA apprend de nous. Les biais ne viennent pas de la machine, mais en réalité de nos propres comportements.* »

Ces témoignages montrent que la confrontation à des exemples concrets permet de transformer une perception initialement confiante en une compréhension plus critique et nuancée. Ils soulignent également l'importance de la sensibilisation pour rendre visibles des mécanismes souvent invisibles, et encourager une réflexion collective sur les usages et les limites de l'intelligence artificielle.

C. Interpellation des étudiants ingénieurs

Nous avons également ciblé notre propre environnement.

Dans une école d'ingénieurs, l'accent est souvent mis sur la performance technique et parfois, l'éthique peut paraître secondaire.

Nous avons donc diffusé un message clé :

Un ingénieur ne crée pas seulement du code, il crée des impacts sociaux.

Cette action a suscité des débats importants, révélant une prise de conscience progressive.

Nous avons donc agis pendant la journée du forum citoyen, nous avons mis en place un stand avec plusieurs activités pour sensibiliser nos camarades.

Nous avons distribué nos flyers et mis en place un questionnaire interactif. (voir annexes)

Enfin, nous avons envoyé une affiche qui est désormais diffusée en continue sur les totems des bâtiments su CESI. (voir annexes)

D. Vulgarisation numérique

Dans le cadre de notre projet, nous avons choisi le format vidéo afin de rendre les enjeux liés aux biais en intelligence artificielle plus accessibles.

Nous avons réalisé deux vidéos sur YouTube :

- **La première** :

Elle porte sur les causes des biais algorithmiques (rôle des données, reproduction des inégalités)

- **La seconde :**

Elle traite de leurs conséquences concrètes (recrutement, justice, santé)

Une troisième vidéo était initialement prévue sous forme d'interview avec un expert. Cependant, celui-ci n'a pas pu se rendre disponible dans les délais.

Nous avons donc choisi de nous appuyer sur les travaux de Yoshua Bengio, spécialiste reconnu de l'intelligence artificielle, afin de conserver une base scientifique solide.

> Cette démarche nous a permis de mettre en avant une idée essentielle :
>
> - les biais ne sont pas une fatalité
> - ils sont le résultat de choix humains

Ainsi, notre objectif a été de sensibiliser le public et d'encourager une utilisation plus critique et responsable de l'intelligence artificielle.

7. Conclusion : responsabilité et perspectives

Ce projet nous a permis de comprendre une réalité essentielle :

l'intelligence artificielle n'est pas neutre.

Elle reflète :

- nos données
- nos choix
- nos sociétés

Les enseignements clé à retenir sont les suivants :

- la technique implique une responsabilité
- la transparence est indispensable
- l'éthique doit être intégrée à la formation

Nous ne ressortons pas de ce projet avec une peur de la technologie, mais avec une meilleure conscience de ses enjeux.

L'IA peut être un outil formidable, à condition d'être conçue de manière responsable !

8. Ressources et annexes

Ressources

https://www.propublica.org/article/machine-bias-risk-assessments-in-criminal-sentencing
https://arxiv.org/abs/1904.02095
https://www.science.org/doi/10.1126/science.aax2342
https://www.bloomberg.com/graphics/2023-generative-ai-bias/
https://gendershades.org/overview.html
https://yoshuabengio.org/
https://www.lucjulia.com/
https://www.youtube.com/

Annexes

Nos prospectus :

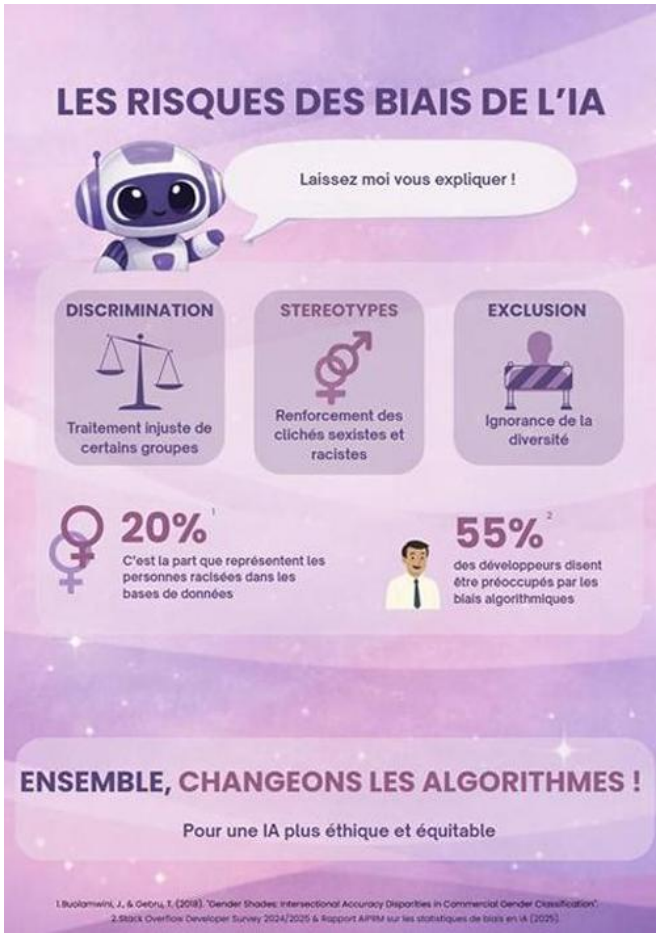

Notre quizz sur les biais de l'IA :

Notre affiche dans les bâtiment du CESI :